דוח מקיף – פרויקט Narrative Lens

זיהוי נרטיבים פוליטיים בטקסט קצר – סיכום כל העבודה, הניסויים והניסיונות

מוגש על ידי: **שירה דורון**

תאריך: **12 באוקטובר 2026**

היקף הדוח: **כל מהלך הפרויקט מתחילתו ועד היום**

תקציר מנהלים

פרויקט **Narrative Lens** בודק האם ניתן לאמן מודל שמסווג טקסט פוליטי קצר (ציוץ/פוסט) לאחד משבעה "נרטיבים" (עמדות/מסגרות אידאולוגיות) — ובעיקר, האם המודל באמת לומד **לזהות את העמדה המובעת בטקסט**, או שהוא בפועל רק "זוכר" **מי כתב** אותו (איזה חשבון/ערוץ). לאורך הפרויקט גילינו שהמודל עובד היטב על נתונים "רגילים", אך נכשל בעקביות כשנבדק על מחבר/חשבון שלא נראה כלל באימון (ירידה של 20–38 נקודות אחוז). ניסינו **מגוון רחב של כיווני התערבות** (מיסוך ישויות, נורמליזציה של סגנון, הסרת רעש בתיוגים, אימון עמיד לקבוצות חלשות/Group-DRO, ועוד) — **כולם נכשלו** בבדיקות אישוש (confirmatory) קפדניות, פרט לאחד. הפתרון היחיד שבאמת עבד היה **Few-shot adaptation**: מתן 10 דוגמאות מתויגות בודדות מהמחבר החדש (בלי לאמן מחדש את כל המודל) החזיר את הביצועים בחזרה לרמה סבירה (מ-39% ל-65% recall בממוצע). במקביל בוצעה עבודת ביקורת איכות נתונים — פיילוט **אנוטציה עיוורת בסיוע מודל** (Blind model-assisted annotation pilot, ראו הבהרה חשובה בפרק 8) — והכנה לסבב תיוג אנושי עצמאי, וכן סבב תחזוקה/אבטחה לפרויקט עצמו (ללא שינוי בתוצאות מחקר קיימות).

1. מבוא ושאלת המחקר המרכזית

> **מושג – מה זה "נרטיב" בפרויקט הזה?**
> לא "סיפור" במובן הרגיל, אלא **עמדה/מסגרת אידאולוגית** שדרכה טקסט מציג אירוע. לדוגמה: אותו אירוע מלחמה יכול להיות מוצג מ"נרטיב רוסי" או מ"נרטיב אוקראיני" — אותם עובדות, זווית אחרת לגמרי.

הפרויקט בודק: בהינתן טקסט פוליטי קצר, האם אפשר לחזות אוטומטית לאיזה מתוך 7 נרטיבים הוא שייך? אבל השאלה המעניינת והחשובה יותר היא: **אם המודל מצליח — האם זה כי הוא באמת הבין את העמדה, או שהוא פשוט "זיהה" את הכותב/חשבון המוכר לו מראש מתוך האימון?** ההבדל קריטי: מודל ש"זוכר כותבים" לא יעבוד כלל על טקסט חדש מכותב לא מוכר בעולם האמיתי — בדיוק המקרה השימושי ביותר בפועל.

2. הדאטהסט (אוסף הנתונים)

16,510 טקסטים בסך הכול, פרוסים על 7 נרטיבים: **10,330 טקסטים אמיתיים** שנאספו מטוויטר (6,877) וטלגרם, ו-**6,180 טקסטים סינתטיים** שנוצרו על ידי מודלי בינה מלאכותית (Gemini 5,600 + GPT 580), כדי להרחיב ולאזן את הדאטהסט.

נרטיב	הסבר פשוט
Zionist (ציוני)	תוכן התואם את העמדה הרשמית/המדינתית הישראלית.
Resistance ("ציר ההתנגדות")	עמדת איראן/חיזבאללה/חמאס וכד' מול ישראל ומערב.
Western (מערבי)	עמדת ממשלות/מוסדות מערביים (נאט"ו, האיחוד האירופי, ארה"ב).
Russian (רוסי)	העמדה הרשמית הרוסית, בעיקר ביחס למלחמה באוקראינה.
Ukrainian (אוקראיני)	העמדה האוקראינית הרשמית מול רוסיה.
Right-wing (ימין אמריקאי)	שמרנות אמריקאית פנים-מדינית.
Left-wing (שמאל אמריקאי)	פרוגרסיביות/שמאל אמריקאי פנים-מדיני.

מגבלה מתודולוגית מרכזית — תיוג מבוסס-מקור (source-derived labels): התיוג של הטקסטים האמיתיים (טוויטר/טלגרם) נקבע **לפי מי פרסם אותם** (איזה חשבון/ערוץ) ולא לפי קריאה/שיפוט אנושי של כל טקסט בנפרד. זו מגבלה מהותית של המחקר כולו (לא הערת שוליים): ייתכן שחלק מהטקסטים אינם מייצגים נאמנה את הנרטיב של החשבון שפרסם אותם. זו גם הסיבה לכך שנדרשת ביקורת איכות נתונים, כולל פיילוט אנוטציה עיוורת (ראו פרק 8) — וגם לשאלת המחקר המרכזית בפרק 1.

3. איך המערכת בנויה (ארכיטקטורה)

תהליך העבודה: **איסוף נתונים** → **עיבוד מקדים** (כולל תרגום טקסט לא-אנגלי) → **חילוץ מאפיינים** → **מיזוג (fusion)** → **סיווג**.

מושג – NER (Named Entity Recognition): זיהוי אוטומטי של "ישויות" בטקסט — שמות אנשים, ארגונים, מדינות (למשל "פוטין", "נאט"ו", "חמאס").

מושג – SRL (Semantic Role Labeling): זיהוי "מי עשה מה למי" במשפט — למשל מי התוקף ומי הקורבן לפי מבנה המשפט עצמו, לא רק לפי מילים בודדות.

מושג – BERTopic (מודל נושאים): כלי שמקבץ טקסטים אוטומטית ל"נושאים" (למשל כל מה שעוסק ב"עזה", כל מה שעוסק ב"אוקראינה") בלי תיוג ידני מראש.

מושג – SBERT (Sentence-BERT): שיטה שהופכת משפט שלם לרשימת מספרים ("embedding") שמייצגת את המשמעות שלו — משפטים דומים במשמעות מקבלים רשימות מספרים דומות.

מושג – Fusion / MLP: "מיזוג" הוא השלב שבו כל המאפיינים שחולצו (NER, SRL, רגש, נושא, SBERT וכו') מחוברים יחד לכדי החלטה אחת. MLP (Multi-Layer Perceptron) הוא סוג בסיסי של רשת נוירונים (שכבות של "חישובים" שלומדים מהדוגמאות) שמבצעת את ההחלטה הסופית.

הפרויקט משווה 3 גרסאות מודל:

מודל	איך הוא עובד	דיוק (Accuracy)	Macro-F1
`baseline_fusion`	מיזוג לינארי פשוט של כל המאפיינים המהונדסים (המודל המקורי)	0.671	0.664
`sbert_only`	רק SBERT קפוא + MLP, בלי שום מאפיין מהונדס אחר	**0.732**	**0.730**
`hybrid`	SBERT + כל המאפיינים המהונדסים יחד, דרך MLP	0.722	0.717

מושג – Macro-F1: ציון שמשלב "דיוק" ו"כיסוי" (האם המודל גם צודק כשהוא חוזה נרטיב מסוים, וגם לא מפספס אותו) בצורה שממוצעת שווה בין כל 7 הנרטיבים — כך שנרטיב "קטן" לא נבלע בממוצע הכללי.

ממצא מפתיע: המודל הפשוט ביותר (`sbert_only`) ניצח את שני המודלים המורכבים יותר — כלומר, כל המאפיינים ה"מהונדסים" (NER/SRL/רגש) לא הוסיפו ערך מדיד מעבר למה ש-SBERT לבדו כבר לוכד, לפחות בפיצול אקראי רגיל של הנתונים (ראו הערה בפרק הבא לגבי פיצולים אחרים).

4. הבעיה המרכזית: כישלון בהכללה לכותבים חדשים (LOAO)

> **מושג – LOAO (Leave-One-Author-Out):** שיטת בדיקה שבה **מוציאים לגמרי** חשבון/מחבר אחד מתוך נתוני האימון, ומודדים כמה טוב המודל מצליח לסווג נכון טקסטים **רק** מאותו מחבר שהוא מעולם לא ראה. זו בדיקה הרבה יותר קשה ומציאותית מפיצול אקראי רגיל.

כשהורץ מבחן LOAO, הדיוק (recall) צנח ב-**20 עד 38 נקודות אחוז** לעומת פיצול אקראי — ו-2 מתוך 3 מחברי הבדיקה "נדדו" בעקביות לתיוג שגוי קבוע (Right-wing). זו הייתה נקודת הפתיחה לכל המחקר שבא אחריה: **האם המודל באמת מבין נרטיב, או רק זוכר מחברים?**

5. כל מה שניסינו כדי לפתור את זה — חמישה עשר שלבי חקירה

הטבלה הבאה מסכמת את כל שלבי החקירה (א–טו, 15 שלבים בסך הכול), לפי הסדר הכרונולוגי שבו הן נשאלו בפועל. רוב השלבים הניבו תוצאה שלילית/מעורבת — אך לא כולם: שלב יג (ו-טו שמאשש אותו) הוא ההתערבות החיובית היחידה שהוכיחה את עצמה:

א. "קיצור דרך" של ישויות (Entity Shortcut) — מעורב

שאלה: האם הנפילה נובעת מכך שהמודל "זוכר" שמות ישויות ספציפיים (כמו "סנדרס", "פוטין") במקום ללמוד עמדה אמיתית?
תוצאה: חלקית — מיסוך זהות הישויות שינה תחזיות, אך לא בעקביות בין מחברים שונים.

ב. מיסוך ישויות באימון (Entity Masking) — מעורב

> **מושג – Masking (מיסוך):** החלפת שם ישות קונקרטי (למשל "ביידן") בתווית כללית (למשל "[אדם]") כדי שהמודל לא "יזכור" שמות ספציפיים אלא ילמד דפוס כללי יותר.

תוצאה: עזר למחבר אחד (Bernie), הזיק לשני מחברים אחרים (IDF, Maria) — אות ניסיוני בלבד, לא עקבי מספיק כדי לאמץ כפתרון.

ג. מבחן אישוש על 14 מחברים חדשים (Fresh-Author Confirmatory Test) — שלילי

> **מושג – מבחן "מאושש" מראש (Pre-registered Confirmatory Test):** מבחן שתנאיו נקבעים **לפני** שרואים את התוצאות, על נתונים חדשים שלא היו מעורבים כלל בפיתוח ההשערה — כדי למנוע מצב של "מתאימים את התיאוריה לתוצאות שכבר ראינו".

תוצאה: כישלון מובהק (`NON-INFERIOR = FALSE`) — מיסוך הישויות לא השתכפל/לא הכליל ל-14 מחברים חדשים. השיטה הזו נסגרה כאן.

ד. אבחון שגיאות (Error Diagnostics) — לא חד-משמעי

שאלה: האם יש מכנה משותף ברור לטקסטים שהמודל טעה בהם?
תוצאה: לא נמצא דפוס כשל יחיד, נקי וברור לפעולה.

ה. "חתימת מחבר" (Author Signature) חיובי — ממצא מפתח

שאלה: האם אפשר לחזות **מי כתב** טקסט (ולא איזה נרטיב) אך ורק לפי סגנון כתיבה גולמי, גם בתוך נרטיב קבוע אחד?

תוצאה: כן, הרבה מעבר למקרי (לדוגמה בנרטיב Western: 85.1% לעומת ~20% רף מקרי). זה ממצא חשוב: **התיוגים עצמם "מכילים" בתוכם זהות מחבר, לא רק תוכן** — בדיוק החשש מפרק 1.

ו. נורמליזציה של סגנון (Style Normalization) שלילי

> **מושג – נורמליזציה של סגנון:** "ניקוי" מאפייני סגנון אישי (פיסוק, אותיות גדולות, אורך משפט וכד') מהטקסט, כדי לנסות "להעלים" את חתימת המחבר ולהשאיר רק תוכן.

תוצאה: הנורמליזציה אכן הפחיתה את אפקט "חתימת המחבר" (כ-15 נקודות macro-F1 פחות), אבל **החמירה** את ההכללה למחברים חדשים ב-13 מתוך 14 מקרים (ירידה ממוצעת 6.4 נקודות אחוז) — כלומר הסרת הסגנון לא הייתה הפתרון, למרות שהגיונית נשמעה כאחד.

ז. בדיקת איכות תיוגים (Blind Model-Assisted Annotation Pilot) חיובי

שאלה: האם שגיאות ה-LOAO נובעות מתיוגים שגויים מלכתחילה בנתוני האימון?

תוצאה: 300 טקסטים עברו אנוטציה עיוורת **בסיוע מודל שפה (ChatGPT)**, ללא חשיפת החשבון או התיוג המקורי (ראו פרק 8). ההסכמה בין האנוטציה הזו לבין התיוג המקורי (מבוסס-מקור) עמדה על 0.7727, עם כ-20% "רעש קשה" (אי-הסכמה ממשית). **חשוב:** זו לא הסכמה בין שני בני אדם — התיוג המקורי נקבע מראש לפי חשבון המקור, והאנוטטור היחיד כאן הוא מודל. התיוגים ברובם עקביים עם המקור, אך זו עדיין לא בדיקה אנושית עצמאית.

ח. הסרת שורות "רועשות" מעורב

תוצאה: הסרת חשבונות/שורות מסומנות כבעייתיות שינתה את הביצועים לכיוונים שונים בהתאם למחבר — לא תיקון נקי ועקבי.

ט. בלבול אירועים (Event Confounding) שלילי — נפסל כהסבר

שאלה: האם הפער נובע פשוט מכך שהאימון והבדיקה עוסקים באירועי חדשות שונים (לא מאותו "זמן")?

תוצאה: לא. גם כששומרים על אותו אירוע בדיוק בין אימון לבדיקה, הפער נשאר גדול יותר (-36.3 נקודות אחוז) מאשר כשהאירועים שונים (-30.9) — כלומר זה לא הסבר לבעיה.

י. סיבתיות ישויות (Entity Causality) שלילי

שאלה: אם מחליפים בזמן הבדיקה שם ישות אחד באחר, האם זה באמת "גורם" לתחזית לשתנות?

תוצאה: כמעט לא (אפקט +0.043 בלבד, קרוב ל"פלסבו") — הזהות מתואמת עם שגיאות אך לא גורמת להן ישירות.

יא. אימון עמיד לקבוצות חלשות (Group-DRO) שלילי

מושג – Group-DRO: שיטת אימון שבמקום לבצע "ממוצע כולל" של הביצועים, היא מתמקדת ב**שיפור הקבוצה הכי חלשה** במכוון (כאן: קבוצות של נרטיב+מחבר) — כדי למנוע מצב שבו מחבר בודד "נבלע" בממוצע הטוב של כולם.

תוצאה: הגדרה שנבחרה בניסוי חקר נכשלה במבחן אישוש על 14 מחברים חדשים (`NOT_SUPPORTED`) — לא עקבי מספיק כדי לאמץ.

יב. בדיקת יציבות רב-זרעית (Multi-seed stability) שלילי

מושג – "זרע" אקראי (Random Seed): מספר שמגדיר את נקודת ההתחלה של תהליך אקראי במחשב. הרצה עם "זרעים" שונים בודקת אם תוצאה חיובית הייתה אמיתית או סתם מזל של הרצה בודדת.

תוצאה: ממצא חיובי קודם (הסרת רעש עוזרת למחבר אחד) התהפך/נעלם כשחזרו עליו עם 3 זרעים שונים — כלומר היה כנראה רעש סטטיסטי ולא אפקט אמיתי.

יג. Few-shot adaptation — הפתרון שבאמת עבד חיובי — הממצא המרכזי של הפרויקט

מושג – Few-shot adaptation (התאמה עם דוגמאות בודדות): במקום לאמן מחדש את כל המודל, פשוט "מראים" לו מספר קטן (כאן: 10) של דוגמאות מתויגות אמיתיות מהמחבר החדש, ונותנים לו להתאים את עצמו על בסיסן בלבד — תהליך זול ומהיר בהרבה מאימון מחדש.

תוצאה: תיוג 10 דוגמאות בלבד ממחבר חדש החזיר את ה-recall מ-39% (ללא כל עזרה) ל-**64.9%** בממוצע — **ההתערבות החיובית הראשונה והיחידה** לאורך כל הקו הזה של המחקר.

יד. חיזוי ביטחון וסירוב לענות (Selective Prediction) מעורב

שאלה: אם המודל "יודע מתי הוא לא בטוח" ונמנע מלענות במקרים כאלה, האם זה משפר את הדיוק?
תוצאה: רמת הביטחון של המודל אכן מזהה שגיאות במידה מסוימת, אך הימנעות מתשובה ב-20% מהמקרים הכי לא-בטוחים שיפרה את הדיוק רק במעט (מ-0.401 ל-0.437) — לא פתרון שלם.

טו. אישוש סופי רב-זרעי ל-Few-shot מעורב-חיובי — סגר את הקו הזה

תוצאה: התוצאה החיובית מ-(יג) נשמרת ברמת k=10 (65.7% בחזרה על 64.9%), אך מתגלה ניואנס חשוב: דוגמה **בודדת אחת** (k=1) לא אמינה ואף מחמירה ב-9 מתוך 14 מחברים, וישנו מחבר אחד (`United24Media`) שעמיד לחלוטין בפני כל כמות של התאמה.

6. מסקנת הביניים המרכזית

מתוך **מגוון רחב של כיווני התערבות שנבדקו**, **רק גישה אחת הוכיחה את עצמה** במבחני אישוש קפדניים: לא לנסות "לתקן" את המודל מראש (zero-shot), אלא לתת לו **מעט דוגמאות אמיתיות מהמחבר החדש** ברגע ההיתקלות הראשון איתו (few-shot). זהו ממצא בעל ערך מעשי ברור: במערכת אמיתית, כדאי להשקיע בתיוג מהיר של כמה דוגמאות מכל מקור חדש, ולא בניסיון לבנות "מודל-על" שמכליל מראש לכל מקור עתידי בלי לראות ממנו כלום.

7. מודל הנושאים (BERTopic) — קו מחקר מקביל

במקביל לקו המחקר הראשי, בוצע קו ניסויים נפרד (א'–ו', המתועד במלואו ב- `EXPERIMENTS.md`) שבדק האם לשפר את "מודל הנושאים" עצמו (BERTopic) יעזור — למשל האם ייצוג נושא "רך" (התפלגות הסתברויות על כמה נושאים, ולא רק נושא יחיד) משפר סיווג נרטיב.

תוצאה עיקרית: ייצוג הנושא ה"קשה" (נושא יחיד) ניצח בארכיטקטורת המיזוג המלאה; התועלת האמיתית של הייצוג ה"רך" התבררה כהפחתת הטיה (bias reduction), לא כשיפור דיוק ישיר. ניסויים נוספים (גודל אשכולות מינימלי, בחירת מודל embedding, יציבות בין זרעים, איחוד נושאים כפולים, מדד LDA קלאסי כהשוואה, והשפעת גודל הקורפוס) בוצעו על עותק נפרד לצורכי מחקר בלבד, ולא אומצו לייצור (`saved_topic_model_soft_v2` אינו משמש כרגע אף מודל סיווג בפועל).

8. ביקורת איכות נתונים: Blind Model-Assisted Annotation Pilot (לקראת Dataset V2)

> **הבהרה מתודולוגית חשובה (לפני כל דבר אחר):** 300 הטקסטים בפיילוט הזה לא עברו תיוג על ידי בן אדם. הם תויגו על ידי **מודל שפה (ChatGPT)**, בצורה "עיוורת" (בלי לראות את שם החשבון או את התיוג המקורי). לכן, בשלב הזה, הציון 0.7727 הוא **הסכמה בין אנוטציה בסיוע מודל לבין תיוג מבוסס-מקור** — לא human agreement, ולא Cohen's kappa בין שני בני אדם. הכינוי המדויק לשלב הזה הוא **Blind model-assisted annotation pilot**.

> **מושג – תיוג עיוור (Blind Annotation):** מתייג (אדם או מודל) מקבל רק את הטקסט עצמו — בלי שם החשבון שפרסם אותו, בלי התיוג ה"רשמי" — כדי לקבוע בעצמו, בלי שום רמז, מה הנרטיב המתאים.

נבנה מדגם עיוור של 300 טקסטים (מתוך כלל הנתונים) ונבדק מול התיוג המקורי **מבוסס-המקור** (ראו המגבלה המתודולוגית בפרק 2): הסכמה 0.7727, עם כ-20% שורות "רעש קשה" (אי-הסכמה ממשית בין האנוטציה בסיוע המודל לבין תיוג המקור). זהו הבסיס לפרק 5-ז — ושוב, זהו תוצר ביניים, לא אימות אנושי.

בשלב הנוכחי: הוכנה חבילת 100 דוגמאות למתייג **אנושי** עצמאי (אדם אמיתי, לא מודל) לצורך חישוב הסכמה בין האנוטציה בסיוע המודל לבין תיוג אנושי (ראו פרק 9). כל חמש בדיקות התקינות שבוצעו (ייחודיות המזהים, היעדר מידע מזהה, ניטרול שמות משתמש/קישורים, עמודות ריקות, התאמה למדגם שהוקפא מראש) עברו בהצלחה, והקובץ מוכן למסירה.

> **מושג – Cohen's Kappa (לשימוש בשלב הבא, בזהירות):** מדד סטטיסטי שבודק עד כמה שני מתייגים מסכימים ביניהם, **בניכוי** ההסכמה שהייתה קורית סתם במקרה. **במקרה שלנו: גם לאחר שהמתייג האנושי העצמאי ישלים את 100 הדוגמאות, אסור להציג את ההסכמה כ-"inter-human agreement" או כקאפא בין שני אנוטטורים אנושיים** — כי צד אחד (הפיילוט המקורי של 300) הוא מודל. יש לתאר זאת במדויק כ"הסכמה בין אנוטציה בסיוע מודל (ChatGPT) לבין אנוטציה אנושית", ולא כקאפא בין-אנושי.

9. עבודת תחזוקה ואבטחה אחרונה (11–12 באוקטובר 2026)

לצד המחקר עצמו, בוצע סבב ממוקד של סידור ובדיקת תשתית הפרויקט:

משימה	מה נבדק/תוקן	סטטוס

בדיקת חשיפת מפתח API	נסרקה כל היסטוריית הגרסאות (Git) בחיפוש מפתח סודי שנחשף בטעות	לא נמצאה חשיפה
תיקון "דריסת" קבצי תוצאות	ניסויי מודל הנושאים כתבו כולם לאותם קבצי פלט וכך מחקו זה את תוצאות זה בטעות	תוקן, בלי לשנות תוצאה קיימת
Git LFS לקבצים גדולים	ניסיון להגדיר ניהול חכם לקבצי מודל גדולים חדשים בלבד	בוטל בינתיים (סיכון לקבצים ישנים), נדחה למשימה עתידית מבוקרת
ניקוי קוד ישן	מחיקת סקריפט חד-פעמי שכבר מילא את תפקידו (המיזוג שהוא ביצע כבר שמור בקובץ הרשמי)	נמחק בבטחה
הכנת חבילת תיוג למתייג השני	5 בדיקות תקינות על קובץ 100 הדוגמאות	מוכן למסירה

בכל אחת מהמשימות הושם דגש על **אי-פגיעה בתוצאות מחקר קיימות** — אלו שינויי תשתית/ניקיון בלבד, לא ניסויים חדשים.

10. מצב נוכחי וצעדים הבאים

- קווי המחקר על הכללה לכותבים חדשים (LOAO) **נסגרו** אחד-אחד — הממצא המעשי המוביל להמשך הוא **Few-shot adaptation**.
- ממתינים לתוצאות המתייג האנושי העצמאי (100 דוגמאות) כדי לחשב הסכמה בין האנוטציה בסיוע המודל לבין תיוג אנושי אמיתי, ולגבש המלצה סופית לדאטהסט V2 (אילו שורות/חשבונות לשמור, להסיר, או לבדוק שוב). יש לדווח על התוצאה כהסכמה model-assisted-vs-human, לא כקאפא בין-אנושי.
- Git LFS (ניהול קבצים גדולים) ממתין למשימת מעבר (migration) מתוכננת ומאושרת בנפרד.

נספח — מילון מושגים מרכזי

מושג	הסבר במילים פשוטות
Narrative (נרטיב)	עמדה/מסגרת אידאולוגית שדרכה מוצג אירוע, לא "סיפור" במובן הרגיל.
SBERT	שיטה שהופכת משפט לרשימת מספרים שמייצגת את משמעותו.
BERTopic	כלי לקיבוץ אוטומטי של טקסטים ל"נושאים" בלי תיוג ידני מראש.
NER	זיהוי שמות ישויות (אנשים, ארגונים, מדינות) בתוך טקסט.
SRL	זיהוי "מי עשה מה למי" במשפט לפי מבנה דקדוקי.
Fusion / MLP	מיזוג כל המאפיינים יחד להחלטה אחת, דרך רשת נוירונים בסיסית.
Macro-F1	ציון דיוק+כיסוי, ממוצע שווה בין כל הנרטיבים (לא נבלע ע"י נרטיב גדול).
LOAO	בדיקה שבה מוציאים לגמרי מחבר אחד מהאימון ובודקים אותו בנפרד.
Masking (מיסוך)	החלפת שם ישות קונקרטי בתווית כללית, כדי להסתיר זהות ספציפית.
Pre-registered / Confirmatory test	מבחן שתנאיו נקבעים מראש, על נתונים חדשים, למניעת הטיה.
Group-DRO	שיטת אימון שמתמקדת בשיפור הקבוצה הכי חלשה, לא רק הממוצע הכללי.

Random Seed (זרע אקראי)	מספר שקובע את נקודת ההתחלה של תהליך אקראי, לבדיקת יציבות תוצאה.
Few-shot adaptation	התאמת מודל קיים בעזרת מספר קטן של דוגמאות חדשות, בלי אימון מחדש מלא.
Selective Prediction	לתת למודל "לסרב לענות" כשהוא לא בטוח, כדי לשפר דיוק על מה שכן נענה.
Blind Annotation	תיוג טקסט בלי לדעת מי כתב אותו או מה התיוג ה"רשמי" — יכול לביצע על ידי אדם או אפילו על ידי מודל; חשוב לציין מי ביצע אותו בכל מקרה.
Model-Assisted Annotation	תיוג שבוצע על ידי מודל שפה (כאן: ChatGPT) ולא על ידי אדם — אסור להציג אותו כ"בדיקה אנושית" או כ-Cohen's kappa בין שני בני אדם.
Source-derived labels (תיוג מבוסס-מקור)	תיוג שנקבע לפי מקור/חשבון הפרסום, לא לפי קריאה אנושית של כל טקסט בנפרד — מגבלה מתודולוגית מרכזית של המחקר.
Cohen's Kappa	מדד הסכמה בין שני מתייגים אנושיים, בניכוי הסכמה שהייתה קורית סתם במקרה — אינו מתאים לתיאור הסכמה מול אנוטציה בסיוע מודל.
Git / Git history	מערכת שמנהלת את כל גרסאות קבצי הפרויקט לאורך זמן, כולל גרסאות ישנות.
API Key	מפתח סודי שמאפשר לתוכנה להתחבר לשירות חיצוני בשם המשתמש.
Git LFS	תוסף ל-Git שמתאים לניהול קבצים גדולים מאוד (כמו קבצי מודל מאומן).

דוח זה נוצר כסיכום מקיף של פרויקט Narrative Lens, על בסיס התיעוד המלא בקבצי הפרויקט (`README.md`, `EXPERIMENTS.md`, `docs/narrative_definitions.md`, `docs/architecture.md`, `docs/results.md`). לפרטים מלאים, מתודולוגיה מדויקת ומספרים נוספים לכל ניסוי — ראו קבצים אלו ישירות בפרויקט.